

Výpočet korelačního koeficientu

Dokumentace k programu

Radek Modrůczki

12. února 2026

Abstrakt

Tento program slouží k výpočtu Pearsonova korelačního koeficientu. Tento ukazatel slouží k efektivní statistické analýze závislosti mezi dvěma číselnými řadami a kvantifikuje sílu lineární vazby. Lze tak posoudit, zda je korelace silně přímo úměrná, či závislá nepřímo. Aplikace je navržena s důrazem na objektově orientovaný přístup a ošetření vstupních dat a singulárních chyb, což zaručuje spolehlivost výsledků.

Obsah

1	Přesné zadání	2
2	Zvolený algoritmus	2
3	Diskuse výběru algoritmu	2
4	Program	3
4.1	Použité datové struktury	3
4.2	Hlavní třídy a podprogramy	3
4.3	Tok řízení	3
5	Alternativní programová řešení	3
6	Reprezentace vstupních dat a jejich příprava	4
6.1	Reprezentace vstupních dat	4
6.2	Příprava a zpracování dat	4
7	Reprezentace výstupních dat a jejich interpretace	4
7.1	Reprezentace výstupních dat	4
7.2	Interpretace výstupních dat	4
8	Průběh práce	4
9	Možná vylepšení	5

1 Přesné zadání

Z textového souboru načtete hodnoty jevů A, B a s využitím Pearsonova korelačního koeficientu ověřte, zda mezi A, B existuje závislost. Pro výpočet korelačního koeficientu nepoužívejte vestavěné funkce.

2 Zvolený algoritmus

Pro analýzu závislosti mezi dvěma datovými řadami byl zvolen výpočet Pearsonova korelačního koeficientu (zde označen jako r). Tento algoritmus kvantifikuje míru lineární závislosti mezi proměnnými x a y . Výsledná hodnota se vždy pohybuje v intervalu $\langle -1, 1 \rangle$, hodnoty blízké mezím intervalu značí silnou závislost (kladnou či zápornou) a hodnota 0 značí lineární nezávislost.

Výpočet vychází ze standardní definice, kdy je korelační koeficient definován jako podíl kovariance a součinu směrodatných odchylek obou veličin.

Vzorec použitý pro výpočet:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (1)$$

Kde n je počet prvků v posloupnosti, x_i a y_i označují jednotlivé hodnoty ze vstupních dat a $\bar{x}$ a $\bar{y}$ jsou aritmetické průměry daných posloupností. Pro implementaci byla zvolena metoda více průchodů.

3 Diskuse výběru algoritmu

Ačkoliv existuje výpočetní vzorec, který umožňuje vypočítat korelaci v jediném průchodu pomocí součtu čtverců, byla zvolena metoda více průchodů. Důvodem této volby je numerická stabilita; jednopřechodové vzorce mohou při práci s velkými čísly s malým rozptylem vést k chybám v zaokrouhlení.

Zvolený algoritmus postupuje takto:

- **Validace vstupu:** Ověření, zda vstupní vektory mají shodnou délku n a zda je počet n vyšší než 2.
- **První průchod – výpočet průměrů:** Iterace přes prvky pro získání aritmetických průměrů $\bar{x}$ a $\bar{y}$.
- **Druhý průchod – výpočet sum:** Iterace pro výpočet čitatele (součet součinů odchylek) a jmenovatele (součty čtverců odchylek).
- **Finalizace:** Odmocnění jmenovatele a provedení finálního dělení.

Jednopřechodový algoritmus by byl paměťově efektivnější a nevyžadoval by uložení celého pole dat v paměti (stačí pracovat se streamem), jeho zásadní nedostatek se však nazývá katastrofická ztráta přesnosti. Tento problém nastává při práci s velkými čísly, která mají nízký rozptyl (např. hodnoty 1 000 001 a 1 000 002). Vlivem omezené plovoucí řádové čárky (`float`) může při odečítání velkých čísel dojít k vyrušení významných číslic nebo k pádu programu (záporná hodnota pod odmocninou).

Z tohoto důvodu byl zvolen algoritmus s více průchody, který počítá odchylky od průměru, pracuje s menšími čísly a je numericky stabilnější.

4 Program

Aplikace je implementována v jazyce Python a využívá objektově orientované programování. Je striktně oddělena výpočetní logika od vstupu a výstupu dat.

4.1 Použité datové struktury

Pro uložení vstupních statistických souborů jsou využity seznamy (`list`). Data jsou v paměti reprezentována jako dva nezávislé seznamy čísel s plovoucí řádovou čárkou. Toto umožňuje přistupovat k i -tému prvku v konstantním čase, což je nezbytné pro efektivní iteraci v cyklech.

4.2 Hlavní třídy a podprogramy

Jádrem aplikace je třída `StatisticsCalculator`, která zapouzdřuje data a poskytuje metody pro jejich zpracování. Tím je zajištěno, že vnitřní stav objektu nelze měnit zvenčí.

Metody třídy `StatisticsCalculator`:

- `load_from_file(filename)` – Zajišťuje kompletní načtení dat z textového souboru. Čte soubor po řádcích, provádí parsování textu na čísla a plní interní seznamy `data_x` a `data_y`. Kontroluje formát každého řádku a nevalidní řádky přeskakuje, aby nedošlo k pádu aplikace.
- `calculate_pearson_correlation()` – Implementuje výše popsany algoritmus. Metoda detekuje singulární případ (nulový rozptyl), kdy by byl jmenovatel roven nule. V tomto případě vyvolá výjimku `ArithmeticError`.
- `_calculate_mean(data)` – Pomocná metoda pro získání aritmetického průměru.

4.3 Tok řízení

Program je řízen blokem `main`, který funguje jako klient třídy `StatisticsCalculator`. Celý proces probíhá v následujících krocích:

1. **Inicializace:** Načtení vstupu a vytvoření instance kalkulátoru.
2. **Načtení dat:** Volání metody `load_data()`, která data parsuje.
3. **Výpočet:** Spuštění metody `calculate_pearson_correlation()`.
4. **Výstup:** Zformátování výsledku a jeho výpis na obrazovku včetně interpretace.

5 Alternativní programová řešení

V prostředí Python je standardem využívání speciálních knihoven, jako např. NumPy, které nabízejí optimalizované funkce v jazyce C. Tato varianta byla zamítnuta pro lepší demonstraci algoritmizace a zajištění přenositelnosti programu (spuštění na jakékoli instalaci Pythonu).

Dále byla zvažována možnost využití pomocné třídy `DataPoint`, která by zapouzdřovala dvojici hodnot x a y . Tento přístup by však znamenal vytváření tisíců instancí objektů, což by bylo časově i paměťově náročnější než práce s jednoduchými poli. Udržování dvou nezávislých seznamů zjednodušuje iteraci a je efektivnější.

6 Reprezentace vstupních dat a jejich příprava

6.1 Reprezentace vstupních dat

Program pracuje s daty uloženými v prostém textovém souboru, který lze editovat například v Poznámkovém bloku. Data jsou organizována po řádcích, kde každý řádek reprezentuje jedno měření (dvojici hodnot x a y).

Na každém řádku se musí nacházet právě dvě čísla oddělená alespoň jednou mezerou nebo tabulátorem. Jako oddělovač desetinných míst se používá tečka; čárky nejsou podporovány a způsobí chybu. Jsou podporována celá čísla i čísla s plovoucí řádovou čárkou.

6.2 Příprava a zpracování dat

Program otevírá soubor v režimu pro čtení a iteruje po řádcích, což šetří paměť. U každého řádku jsou odstraněny přebytečné znaky a prázdné řádky jsou přeskočeny. Neprázdný řádek je rozdělen funkcí `split` na tokeny. Pokud počet tokenů není 2, řádek je považován za chybný. Program se následně pokusí převést řetězec na typ `float`. V případě chyby je zachycena výjimka `ValueError`.

7 Reprezentace výstupních dat a jejich interpretace

7.1 Reprezentace výstupních dat

Výstup je směřován na standardní výstup konzole. Výsledek je strukturován do více řádků pro vyšší přehlednost a numerická hodnota je zaokrouhlena na 4 desetinná místa (formát: Pearsonův koeficient: X.XXXX).

7.2 Interpretace výstupních dat

Program automaticky provádí interpretaci vypočtené hodnoty a slovně hodnotí sílu závislosti. Rozlišují se následující intervaly:

- **Silná přímá závislost** ($r > 0.7$): Hodnota se blíží +1, s růstem jedné veličiny roste i druhá.
- **Silná nepřímá závislost** ($r < -0.7$): Hodnota se blíží -1, s růstem jedné veličiny druhá klesá.
- **Žádná nebo slabá závislost** ($-0.3 < r < 0.3$): Hodnota je blízká nule, lineární vztah pravděpodobně neexistuje.
- **Mírná závislost**: Ostatní případy; závislost existuje, ale není silná.

8 Průběh práce

Jako první bylo důležité zjistit formuli výpočtu korelačního koeficientu a rozvrhnout strukturu tříd. Logika výpočtu byla oddělena od uživatelského rozhraní do třídy `StatisticsCalculator`, což zjednodušilo psaní kódu. Během implementace bylo nutné zajistit odolnost programu vůči nekorektním vstupům (např. prázdné řádky) a ošetřit matematické chyby, jako je dělení nulou při nulovém rozptylu dat.

9 Možná vylepšení

Bylo by možné rozšířit program o podporu vstupních souborů ve formátu CSV s hlavičkou. V aktuální verzi byl upřednostněn jednodušší formát bez hlavičky pro přehlednost kódu. Dalším možným rozšířením je grafická vizualizace dat (např. bodový graf) pro odhalení trendů a shluků, což by však vyžadovalo použití externích knihoven.